



Bài báo cáo cuối kỳ/Nghiên cứu

**KHAI PHÁ TRI THỨC TỪ DỮ LIỆU VẬN HÀNH POS
VỚI QUY TRÌNH CRISP-DM VÀ HỌC MÁY KHÔNG GIÁM SÁT**

Trần Hoàng Đạt¹, Võ Văn Minh¹, Nguyễn Trần Bảo Thái¹

¹ Nơi công tác: Đại học Sư phạm Thành phố Hồ Chí Minh

*Tác giả liên hệ: Trần Hoàng Đạt; Email: hoangdattran12@gmail.com

Received:; Revised :; Accepted:

Tóm tắt

Hệ thống Điểm bán hàng (POS) trong ngành bán lẻ và F&B tạo ra lượng lớn dữ liệu giao dịch hàng ngày. Tuy nhiên, việc kiểm toán và phát hiện rủi ro thất thoát tiền mặt thường gặp nhiều thách thức do dữ liệu vận hành thực tế không có nhãn giám sát, độ trễ giữa doanh thu máy tính và số tiền nhân viên thực nhập tay cuối ca, cùng lượng lớn thông tin phi cấu trúc (từ lóng, viết tắt). Các phương pháp kiểm toán thủ công tốn nhiều thời gian, trong khi việc ứng dụng các Mô hình Ngôn ngữ Lớn (LLM) bị giới hạn bởi chi phí tính toán tại các điểm bán lẻ nhỏ. Nghiên cứu này đề xuất một giải pháp tiếp cận lai (Hybrid Approach) dựa trên quy trình CRISP-DM, kết hợp Học máy không giám sát (K-Means Clustering, kiểm chứng chéo bằng DBSCAN) và Hệ chuyên gia (Rule-based Engine). Thuật toán K-Means được áp dụng để cô lập các mẫu rủi ro ẩn từ 236 ca làm việc, nhận diện thành công cụm dị biệt có mức độ lệch kết cực đoan (C0) và cụm rủi ro do tải trọng giao dịch cao (C3). Song song đó, kỹ thuật Fuzzy Grouping và IQR được sử dụng để trích xuất hành vi từ dữ liệu ghi chú phi cấu trúc. Dựa trên các phát hiện này, một Rule Engine được thiết kế để tự động dân nhãn rủi ro và sinh báo cáo ngôn ngữ tự nhiên. Kết quả đã tự động hóa việc đánh giá rủi ro cho bộ dữ liệu POS Master gồm 36 đặc trưng với độ minh bạch cao. Đóng góp chính của bài báo là việc xây dựng thành công kiến trúc kiểm toán “Zero-LLM” gọn nhẹ, giải quyết hiệu quả bài toán văn bản tiếng Việt ngắn, cho phép triển khai trực tiếp trên các thiết bị POS viền (edge devices) mà không phụ thuộc vào điện toán đám mây.

Từ khóa: Khai phá dữ liệu, Kiểm toán POS, Học máy lai (Hybrid Machine Learning), K-Means Clustering, Fuzzy Grouping, Hệ chuyên gia (Rule-based Engine), Quy trình CRISP-DM.

1. Giới thiệu

Trong kỷ nguyên số hóa, các hệ thống Điểm bán hàng (POS) đóng vai trò là trái tim vận hành của ngành bán lẻ và dịch vụ ăn uống (F&B), tạo ra một khối lượng khổng lồ dữ liệu giao dịch mỗi ngày. Mặc dù công nghệ đã hỗ trợ tự động hóa nhiều quy trình, việc kiểm toán và phát hiện rủi ro thất thoát tiền mặt (cash leakage/fraud) tại các cửa hàng vẫn là một thách thức lớn đối với các nhà quản lý. Khó khăn cốt lõi xuất phát từ độ trễ giữa hệ thống ghi nhận doanh thu và số tiền nhân viên thực nhập tay vào cuối ca, đi kèm với đó là lượng lớn dữ liệu ghi chú phi cấu trúc chứa nhiều từ lóng, viết tắt đặc thù trong tiếng Việt. Các phương pháp kiểm toán thủ công truyền thống không chỉ tiêu tốn nhiều thời gian, nguồn lực mà còn dễ bỏ sót các mẫu rủi ro tinh vi.

Nghiên cứu về phát hiện gian lận và rủi ro trong bán lẻ/tài chính đã thu hút nhiều sự

chú ý. Tuy nhiên, các cách tiếp cận hiện tại thường gặp những giới hạn nhất định khi áp dụng vào thực tế vận hành POS. Nhiều nghiên cứu trước đây chủ yếu sử dụng các mô hình học máy có giám sát như Mạng nơ-ron nhân tạo (ANN) hay Hồi quy Logistic (Yusuf Sahin, 2011). Phương pháp này đòi hỏi bộ dữ liệu phải được gán nhãn minh bạch, trong khi dữ liệu vận hành POS thực tế lại không có nhãn giám sát (unlabeled data). Thêm vào đó, do rào cản bảo mật, việc tiếp cận dữ liệu gian lận thực tế là rất khó khăn, buộc nhiều nhà nghiên cứu phải phát triển các công cụ để tạo dữ liệu giả lập (synthetic data) nhằm huấn luyện mô hình (Lopez-Rojas, 2016). Mặt khác, đối với các thuật toán không giám sát như K-Means, các nghiên cứu trong ngành bán lẻ thương mại điện tử thường chỉ dừng lại ở bài toán phân khúc hành vi khách hàng (Ardo Kusdaryanto, 2026), chưa được tận dụng triệt để để cô lập rủi ro vận hành.

Bên cạnh đó, sự phát triển của các Mô hình Ngôn ngữ Lớn (LLM) gần đây mang lại năng lực xử lý văn bản phi cấu trúc mạnh mẽ. Tuy nhiên, việc tích hợp LLM vào hệ thống POS vấp phải rào cản lớn về chi phí tính toán, độ trễ và sự phụ thuộc vào Internet. Đối với các chuỗi bán lẻ vừa và nhỏ, việc triển khai một giải pháp trực tiếp trên các thiết bị viễn (edge devices) là yêu cầu thực tiễn cấp thiết.

Để giải quyết các hạn chế trên, nghiên cứu này đề xuất một giải pháp tiếp cận lai (Hybrid Approach) tuân thủ quy trình CRISP-DM. Khác với các nghiên cứu dùng dữ liệu mô phỏng, chúng tôi trực tiếp khai phá bộ dữ liệu POS Master thực tế gồm 36 đặc trưng từ 236 ca làm việc (tương đương 5 tháng). Kiến trúc đề xuất tích hợp Học máy không giám sát sử dụng K-Means Clustering được kiểm chứng chéo bằng DBSCAN để nhận diện cụm lệch kết cực đoan kết hợp với một Hệ chuyên gia (Rule-based Engine) được thiết lập bằng kỹ thuật IQR và Fuzzy Grouping để đánh giá các hành vi từ văn bản phi cấu trúc và thiết lập ngưỡng cảnh báo.

Đóng góp chính của bài báo là việc xây dựng thành công kiến trúc kiểm toán theo quy tắc “Zero-LLM” gọn nhẹ nhưng có độ minh bạch cao. Giải pháp này tự động hóa hoàn toàn quy trình dán nhãn, giải quyết triệt để bài toán văn bản tiếng Việt ngắn và cho phép triển khai mượt mà trên thiết bị POS viễn mà không cần điện toán đám mây. Phần còn lại của bài báo được cấu trúc như sau: Mục 2 trình bày phương pháp đề xuất và quá trình phân tích dữ liệu; Mục 3 thảo luận về kết quả thực nghiệm và cơ chế của hệ chuyên gia; Mục 4 đưa ra các kết luận và hướng phát triển.

2. Phương pháp đề xuất

2.1 Phân tích nghiệp vụ và bộ dữ liệu

Trong quá trình triển khai và vận hành thực tế một hệ thống POS (do chính tác giả tự thiết kế, lập trình và cung cấp thương mại riêng cho một khách hàng trong lĩnh vực bán lẻ/F&B), một lỗ hổng kiểm soát tài chính đã được ghi nhận: sự chênh lệch giữa doanh thu do hệ thống tính toán và số tiền mặt vật lý thực tế do nhân viên đếm tay vào cuối ca. Bài toán đặt ra là làm thế nào để tự động phân loại, giải thích và cảnh báo các sai lệch này trong điều kiện dữ liệu vận hành hoàn toàn không có nhãn giám sát (tức là không có bất kỳ ai đánh nhãn “ca này bị gian lận” hay “ca này bình thường”). Phân tích nghiệp vụ từ hệ


thông POS cụ thể này chỉ ra ba vấn đề cốt lõi:

- Sai lệch kết không giải thích được: Tình trạng chênh lệch tiền mặt (Cash_Diff) xuất hiện ở nhiều ca nhưng không có thông tin trực tiếp chỉ ra nguyên nhân (do nhầm lẫn loại tiền, thói sai tiền cho khách, hay nhân viên cố tình gian lận). Quản lý cửa hàng hiện phải dò tay từng ca rất tốn thời gian.
- Lãng phí dữ liệu phi cấu trúc: Để tối ưu vận hành, hệ thống POS này được thiết kế cho phép nhân viên nhập tay các ghi chú giao dịch bằng văn bản tự do (ví dụ: viết tắt tên khách hàng, từ lóng như “n9oc pt”, “c hải”). Đây là nguồn dữ liệu quý giá để truy vết hành vi nhưng lại bị bỏ ngỏ do tính chất phi cấu trúc.
- Thiếu cơ chế cảnh báo tự động: Phần mềm POS ban đầu chỉ đóng vai trò lưu trữ số liệu thô. Chủ cửa hàng thường chỉ phát hiện lệch tiền vào kỳ chốt sổ cuối tháng, dẫn đến việc quá muộn để truy vết rủi ro.

Từ các vấn đề trên, nghiên cứu hướng đến việc trả lời các câu hỏi: (1) Liệu có thể phân cụm tự nhiên các ca làm việc thành các nhóm rủi ro có ý nghĩa nghiệp vụ bằng thuật toán không giám sát? (2) Kỹ thuật khai phá văn bản có đủ khả năng chuẩn hóa ghi chú viết tắt của nhân viên để tìm ra bất thường? và (3) Một hệ chuyên gia (Rule Engine) có thể tự động sinh ra khuyến nghị hành động mà không cần dùng đến các Mô hình ngôn ngữ lớn (LLM) đắt đỏ hay không?

2.2 Quy trình CRISP-DM và cơ sở lý thuyết

Nghiên cứu này tuân thủ quy trình chuẩn CRISP-DM (Cross-Industry Standard Process for Data Mining) được biểu diễn ở *Hình 1*, một khung phương pháp luận định hướng doanh nghiệp được xây dựng vào cuối thập niên 1990 và chính thức công bố vào vài năm sau đó (Rüdiger Wirth, 2000), vẫn là tiêu chuẩn thực tiễn phổ biến nhất trong khai phá dữ liệu công nghiệp (Umair Shafique, 2014).



Hình 1. Quy trình CRISP-DM được đề xuất áp dụng vào bài kiểm toán

Điểm vượt trội của CRISP-DM so với quy trình KDD (Knowledge Discovery in Databases) truyền thống nằm ở tính lặp có kiểm soát, một số giai đoạn có thể quay lại giai đoạn được trước khi phát sinh phát hiện mới, phù hợp với bài toán phân tích tài chính. Quy trình gồm sáu giai đoạn tuần hoàn:

- **Hiểu nghiệp vụ (Business Understanding):** Xác định mục tiêu kinh doanh, ràng buộc vận hành và câu hỏi nghiên cứu trước khi tiếp cận dữ liệu. Trong nghiên cứu này, giai đoạn này được thực hiện trong quá trình triển khai hệ thống POS cho khách hàng và không thuộc pipeline kỹ thuật (chi tiết tại Mục 2.1).
- **Hiểu dữ liệu (Data Understanding):** Khám phá cấu trúc, phân phối và chất lượng dữ liệu thô thông qua phân tích thống kê mô tả và trực quan hóa.
- **Chuẩn bị dữ liệu (Data Preparation):** Làm sạch, biến đổi và tích hợp dữ liệu thành tập dữ liệu phân tích thống nhất, sẵn sàng cho mô hình hóa.
- **Mô hình hóa (Modeling):** Lựa chọn, xây dựng và tinh chỉnh các mô hình phân tích phù hợp với đặc điểm dữ liệu và mục tiêu nghiệp vụ.
- **Đánh giá (Evaluation):** Kiểm chứng kết quả mô hình không chỉ theo tiêu chí kỹ thuật mà còn theo mức độ đáp ứng mục tiêu kinh doanh ban đầu.
- **Triển khai (Deployment):** Chuyển đổi kết quả phân tích thành sản phẩm có thể sử dụng.

dụng trong vận hành thực tế.

2.3 Kiến trúc Pipeline xử lý đề xuất


2.3.1. Tổng quan Pipeline

Các giai đoạn kỹ thuật của CRISP-DM được hiện thực hóa thành bốn vòng xử lý tuần tự, trong đó Vòng 2 và Vòng 3 chạy song song trên hai luồng dữ liệu độc lập trước khi hợp nhất tại Vòng 4. *Bảng 1* trình bày ánh xạ đầy đủ giữa các giai đoạn CRISP-DM và các vòng xử lý kỹ thuật.

Bảng 1. Ánh xạ CRISP-DM và Pipeline kỹ thuật

Giai đoạn CRISP-DM	Vòng xử lý	Kỹ thuật chính	Đầu ra
01. Business Understanding	Tiền đề, nằm ngoài pipeline	Phân tích nghiệp vụ	Tri thức vận hành
02. Data Understanding & 03. Data Preparation	Vòng 1 – Mô tả	EDA, merge_asof, Feature Engineering	Audit_Merged_Data.csv
04. Modeling	Vòng 2 – Chẩn đoán	K-Means, DBSCAN, Agglomerative Ward, PCA	Clustered_Shifts.csv
04. Modeling	Vòng 3 – Hành vi khách	Fuzzy Grouping, IQR per-customer	Customer_Pattern.csv
05. Evaluation & 06 Deployment	Vòng 4 – Đề xuất	Rule Engine (R1–R3), sinh báo cáo <u>ur động</u>	Rule_Engine_Report.csv, POS_Master.csv

Mỗi vòng nhận đầu vào từ vòng trước và xuất một tập dữ liệu cụ thể làm nền tảng cho vòng tiếp theo, đảm bảo tính truy vết và tái sử dụng toàn bộ luồng xử lý. Kiến trúc tổng thể được trình bày tại *Hình 2* sau:




Hình 2. Pipeline xử lý kỹ thuật

2.3.2. Vòng 1 - Phân tích mô tả


Vòng 1 thực hiện đồng thời hai giai đoạn Hiểu dữ liệu và Chuẩn bị dữ liệu của CRISP-DM. Đầu vào gồm hai tập dữ liệu: *MainLog.csv* (242 bản ghi chốt ca) và *DetailsTransaction.csv* (5.412 giao dịch chi tiết).

Khám phá dữ liệu (EDA): Các biểu đồ được sử dụng để khảo sát toàn diện phân phối và mối quan hệ giữa các biến: biểu đồ phân phối mật độ (KDE), biểu đồ hộp (boxplot),


biểu đồ phân tán (scatter plot), ma trận tương quan (heatmap) và chuỗi thời gian tỷ lệ tiền mặt. Cụ thể với các sơ đồ sau




Hình 3. Biểu đồ KDE phân phối sai lệch tài chính theo ca



Hình 4. Biểu đồ phân loại ca Sáng/Chiều theo độ lệch




Hình 5. Biểu đồ Boxplot so sánh ca sáng và ca chiều



Hình 6. Heatmap biểu diễn tương quan các chỉ số kiểm toán

Theo như các Hình 3, 4, 5 và 6. Quá trình EDA đã phát hiện hai tính chất quan trọng làm tiền đề cho các vòng sau: biến *Payment_Mismatch* bằng 0 tuyệt đối trên toàn bộ 236 ca (không tồn tại lỗi nhập sai phương thức thanh toán), và biến *Cash_Diff* có sự phân cực rõ rệt giữa ca sáng và ca chiều, phù hợp với đặc điểm vận hành đã xác lập ở giai đoạn Hiểu nghiệp vụ. Được tổng hợp lại ở Hình 7 sau:



Hình 7. Hai biểu đồ phân phối ghép nối loại tiền theo thực thời gian

Ngoài ra, hai bộ dữ liệu vốn không có khóa chung trực tiếp để đối chiếu (do được thiết kế trên Apps Script và Google Sheets), hàm `merge_asof(direction='forward')` được áp dụng để ánh xạ mỗi giao dịch chi tiết vào ca làm việc gần nhất về mặt thời gian. Sáu ca có doanh thu bằng 0 bị loại khỏi phân tích, còn lại 236 ca hợp lệ. Từ đây nhóm tiến hành Xây dựng đặc trưng (Feature Engineering):


Sáu đặc trưng kiểm toán mới được tạo ra từ dữ liệu thô: *Cash_Diff* (chênh lệch kết), *Payment_Mismatch* (lệch phương thức thanh toán), *Revenue_Mismatch* (lệch doanh thu), *Cash_Ratio* (tỷ lệ tiền mặt trên tổng doanh thu), *CashDiff_Ratio* (tỷ lệ lệch kết so với doanh thu ca) và *Shift_Velocity* (tốc độ giao dịch trung bình trong ca).

Trong đó, *CashDiff_Ratio* là đặc trưng then chốt cho Vòng 2 vì cho phép so sánh mức độ lệch kết tương đối thay vì giá trị tuyệt đối, tránh thiên kiến với các ca có doanh thu cao. Đầu ra của Vòng 1 là tập *Audit_Merged_Data.csv* gồm 236 bản ghi đã được làm sạch và chuẩn hóa, đóng vai trò là nguồn dữ liệu gốc duy nhất cho toàn bộ pipeline.


2.3.3. Vòng 2 – Chẩn đoán rủi ro

Vòng 2 thuộc giai đoạn Mô hình hóa của CRISP-DM, tập trung phân cụm 236 ca làm việc thành các nhóm hành vi rủi ro có ý nghĩa nghiệp vụ. Toàn bộ đặc trưng số được chuẩn hóa bằng phương pháp RobustScaler nhằm giảm ảnh hưởng của các ca lệch kết cực đoan lên quá trình tối ưu tâm cụm.

So sánh Metrics Clustering (k = 2 → 7)




Hình 8. So sánh tiêu chí của các thuật toán phân cụm từ k=2 đến k=7



Hình 9. Biểu đồ Silhouette phân tích chất lượng phân cụm


Về lựa chọn số cụm $k=4$, vì K-Means yêu cầu xác định k trước, nghiên cứu sử dụng bốn chỉ số đánh giá nội bộ trên dải k từ 2 đến 7. Đường Elbow cho thấy quán tính (inertia) giảm mạnh từ $k=2$ đến $k=4$ (từ 940 xuống 524,6) rồi chậm lại rõ rệt (*Hình 8 - Elbow*). Ngoài ra, *Hình 8* cũng cho rằng chỉ số Davies-Bouldin tại $k=4$ là 1.004, cao nhất trong dải khảo sát, phản ánh ranh giới không sắc nét giữa cụm C1 và C3 vốn có nhiều ca giao thoa trong thực tế. Chỉ số Calinski-Harabasz tại $k=4$ là 120.6 và duy trì ổn định khi tăng số k .


Trong khi đó ở *Hình 9*, chỉ số Silhouette tại $k=4$ đạt trung bình 0.271; mặc dù $k=2$ cho giá trị cao hơn (cụ thể là 0.820 ở *Hình 8*), phương án hai cụm chỉ phân biệt “bình thường” và “bất thường” mà không tách được các loại rủi ro khác nhau về mặt nghiệp vụ. Vì thế, quyết định chọn $k=4$ dựa đồng thời trên điểm gãy Elbow rõ ràng, bốn cụm kết quả có hành vi nghiệp vụ phân biệt được, và kết quả kiểm chứng từ *Hình 10* sau:




Hình 10. Kiểm tra phân cụm với Dendrogram – Agglomerative

Hình 10. kiểm chứng chéo bằng DBSCAN và Agglomerative Ward để khắc phục giả định hình cầu của K-Means, hai thuật toán phân cụm độc lập được chạy song song. Trong đó, Agglomerative Ward (phân cụm phân cấp kết tụ từ dưới lên) cắt Dendrogram tại độ cao 14,25 cho ra bốn nhánh tự nhiên.






Hình 11. PCA2D của K-means k=4, Agglomerative Ward và DBSCAN




Hình 12. Đồ thị khoảng cách đến láng giềng k=5

Hình 11 biểu diễn hai thuật toán Ward và K-Means trên PCA2D không gán nhãn cho thấy hoàn toàn giống nhau và gần như đồng thuận về cấu trúc phân nhóm chính, đặc biệt về hai ca outlier C0, cụ thể là chỉ số ARI (Adjusted Rand Index) giữa kết quả của Ward và K-Means đạt 0.305.


Trong khi đó, ngưỡng ϵ của DBSCAN được xác định bằng đồ thị khoảng cách đến láng giềng thứ 5 (k-Distance Graph, Hình 12), cho giá trị $\epsilon=3.116$ tại điểm khuỷu. Với $\epsilon=3.1$ và $\text{min_samples}=5$, DBSCAN gán nhãn nhiều cho đúng hai điểm nằm tít ngoài không gian PCA, trùng khớp chính xác với cụm C0 của K-Means (Hình 11).




Hình 13. Radar biểu diễn đặc trưng cụm sau chuẩn hóa nhị nguyên




Hình 14. Sơ đồ Heatmap Centroid phân tích tâm cụm



Hình 15. Sơ đồ Boxplot phân tích chỉ số chính theo các cụm



Hình 16. Sơ đồ scatter phân bố cụm trong không gian



Hình 17. Sơ đồ phân phối tỉ lệ các cụm theo ca sáng/chiều


Sơ đồ của Hình 13, 14, 15, 16, 17 cho thấy đặc trưng, phân bố và phân phối của các cụm sau khi chuẩn hóa, giúp nhóm chúng tôi xây dựng hồ sơ hành vi cho từng cụm:

- Cụm C0 (2 ca, ngoại lai) có *CashDiff_Ratio* đạt 13.95, cao hơn 15 lần so với trung bình do tiền tích lũy từ nhiều ca trước chưa được nộp, toàn bộ hai ca này đều thuộc ca chiều (Hình 14).
- Cụm C1 (96 ca) là nhóm cơ sở với tất cả chỉ số gần 0 trong không gian chuẩn hóa (ánh xạ từ Hình 15 – *Bill ca theo cụm*).
- Cụm C2 (28 ca) có số lượng hóa đơn và doanh thu cao nhất, các ca vận hành bận rộn bất thường (ánh xạ từ Hình 15 – *Doanh thu theo cụm*).
- Cụm C3 (110 ca, đông nhất) có áp lực giao dịch ở mức cao vừa phải với gần 65% thuộc ca sáng, nhóm dễ xảy ra sai sót thời tiền do tải công việc cao. Được ánh xạ qua sơ đồ Hình 17.

2.3.4. Vòng 3 – Phân tích hành vi khách hàng

Vòng 3 là nhánh xử lý độc lập song song với Vòng 2, thuộc giai đoạn Mô hình hóa của CRISP-DM. Đầu vào là 101 ghi chú trong cột *notes* của *DetailsTransaction.csv*, văn bản tự do do nhân viên nhập tay theo thói quen cá nhân, chứa nhiều biến thể viết tắt và không dấu của cùng một tên khách hàng.


Chuẩn hóa văn bản bằng Fuzzy Grouping: Các kỹ thuật xử lý chuỗi truyền thống (tách từ, loại dấu, chuyển thường, xóa khoảng trắng thừa) được kết hợp với khớp chuỗi mờ (fuzzy string matching) để gom các biến thể khác nhau của cùng một tên về một mã định danh thống nhất. Phương pháp này được lựa chọn thay cho các mô hình ngôn ngữ vì tập 101 mẫu quá nhỏ để tinh chỉnh bất kỳ mô hình học sâu nào, và đặc điểm viết tắt kiểu nhân tin (như “n9oc pt” cho “Ngọc PT”) không nằm trong phân phối huấn luyện của các mô hình ngôn ngữ tiếng Việt hiện có (PhoBERT).




Hình 18. Biểu đồ phân phối hành vi đặc trưng ba khách quen

Sau khi gom nhóm, mỗi khách hàng được xây dựng hồ sơ thói quen thanh toán gồm các chỉ số: tỷ lệ phần trăm giao dịch chuyển khoản, giá trị trung bình đơn hàng, và khoảng phân vị giá trị đơn hàng (Hình 18). Phân tích cho thấy ba khách hàng quen có thói quen

khác biệt rõ ràng: “C Trang” và “Ngọc PT” thanh toán gần như hoàn toàn qua chuyển khoản, trong khi “Chú Hải” ưu tiên tiền mặt.



Hình 19. Biểu đồ Boxplot phân phối giá trị đơn
TIMELINE BẤT THƯỜNG THEO TỪNG KHÁCH




Hình 20. Biểu đồ Timeline bất thường theo từng khách quen

Theo như *Hình 19* và *20* biểu diễn, mỗi khách hàng được giám sát độc lập dựa trên hồ sơ riêng của họ. Phương pháp khoảng tứ phân vị (IQR) phát hiện hai loại dị biệt: Dị biệt giá trị (giao dịch có giá trị vượt ngưỡng $Q3 + 1,5 \times IQR$ của khách đó) và dị biệt phương thức (giao dịch được ghi nhận bằng phương thức khác với thói quen chiếm ưu thế của khách). Loại dị biệt thứ hai đặc biệt có giá trị kiểm toán vì một khách hàng quen chuyển khoản xuất hiện một giao dịch tiền mặt có thể chỉ ra việc nhân viên nhận tiền mặt nhưng nhập sai phương thức để giữ lại.

Đầu ra là *Customer_Pattern.csv* gồm 101 giao dịch đã được gán nhãn khách hàng và đánh dấu cờ cảnh báo, làm tín hiệu bổ sung cho Rule Engine ở Vòng 4.

2.3.5. Vòng 4 – Hệ chuyên gia và triển khai

Vòng 4 bao gồm đồng thời giai đoạn Đánh giá và Triển khai của CRISP-DM. Thay vì áp dụng trực tiếp nhãn cụm từ Vòng 2 hay cờ dị biệt từ Vòng 3 như là kết quả cuối cùng, một tầng Logic kế toán (Rule Engine) được thiết kế để tích hợp và diễn giải các tín hiệu này trong ngữ cảnh nghiệp vụ cụ thể. Ba quy tắc kế toán: Rule Engine hoạt động theo ba quy tắc điều kiện tất định theo *Hình 21* sau biểu diễn:



Hình 21. Tổng quan hệ chuyên gia hỗ trợ phân loại ca kiểm toán

- R1 - Nhầm phương thức thanh toán: $Cash_Diff < 0$ đồng thời $Payment_Mismatch > 0$. Tiền không thất thoát, chỉ sai sổ sách do nhân viên bấm nhầm loại thanh toán.
- R2 - Nghi thất thoát thu ngân: $Cash_Diff < 0$ nhưng tất cả chỉ số đối soát hóa đơn đều khớp. Đây là cờ rủi ro cao nhất vì không có lý do kế toán nào giải thích được

khoản hụt.

- R3 - Dự kết bất thường: $Cash_Diff > 0$ vượt ngưỡng. Thường do tiền ca sáng chưa được nộp và tích lũy sang ca chiều, phù hợp với đặc điểm vận hành đã xác lập ở giai đoạn Business Understanding.

Phân tầng mức độ rủi ro: Mức độ nghiêm trọng được xác định bằng cách kết hợp quy tắc vi phạm với nhãn cụm K-Means và tín hiệu từ Vòng 3. Mức Cao được kích hoạt khi R2 đồng thời xuất hiện dị biệt thanh toán từ Vòng 3, chỉ ra khả năng gian lận có chủ ý cao. Mức Trung bình được gán cho R2 kết hợp với cụm C3 (tải cao), gợi ý nguyên nhân là sai sót do áp lực công việc hơn là cố ý. Mức Chú ý áp dụng cho R3 và các dị biệt đơn lẻ từ Vòng 3. Cơ chế kết hợp này giúp lọc bỏ cảnh báo sai, ví dụ, cụm C0 có $Cash_Diff$ cực cao nhưng được xác định là R3 (dự kết do bàn giao ca) thay vì phân loại nhầm thành gian lận.

Sinh báo cáo ngôn ngữ tự nhiên: Thay vì xuất thông số kỹ thuật thuần túy, hệ thống sử dụng cơ chế sinh văn bản theo mẫu (f-string template) để dịch các giá trị số thành câu cảnh báo tiếng Việt có cấu trúc, bao gồm thông tin ca, quy tắc vi phạm, mức độ rủi ro và khuyến nghị hành động cụ thể. Phương pháp này không sử dụng mô hình ngôn ngữ lớn, đảm bảo tính tất định, không có độ trễ và không phụ thuộc kết nối mạng.

Đầu ra gồm *Rule_Engine_Report.csv* (236 ca đã phân loại với khuyến nghị) và *POS_Master.csv* (bảng tổng hợp 236 hàng $\times$ 36 cột tích hợp toàn bộ kết quả pipeline, phục vụ làm kho dữ liệu cho các vòng phân tích tiếp theo).

3. Kết quả thực nghiệm và thảo luận

3.1 Kết quả Vòng 1 — Làm sạch dữ liệu và phát hiện EDA

Sau khi ghép nối và lọc, tập dữ liệu phân tích gồm 236 ca hợp lệ trong khoảng thời gian từ cuối tháng 12/2025 đến hết tháng 4/2026. Phân tích EDA cho thấy các phát hiện:


- Thứ nhất, biến *Payment_Mismatch* bằng 0 trên toàn bộ 236 ca, được xác nhận qua ba biểu đồ độc lập (Hình 3. KDE, Hình 4: scatter, Hình 5: boxplot), đã loại trừ khả năng sai sót nhập phương thức thanh toán khỏi không gian nguyên nhân, thu hẹp bài toán kiểm toán về phía sai lệch kết ($Cash_Diff$) và hành vi khách hàng.
- Thứ hai, $Cash_Diff$ có giá trị trung bình +771.148đ và phân phối lệch phải rõ rệt, kết thường dư hơn là hụt. Ca chiều có $Cash_Diff$ cao hơn và phân tán hơn so với ca sáng một cách có hệ thống, phù hợp với cơ chế bàn giao tiền mặt giữa hai ca.
- Thứ ba, tỷ lệ tiền mặt (*Cash_Ratio*) dao động trong khoảng 40% đến 80% trong suốt năm tháng quan sát và không có xu hướng mùa vụ (Hình 7). Điều này xác nhận rủi ro xuất phát từ thói quen vận hành cố hữu hơn là biến động thời gian, có ý nghĩa quan trọng cho chiến lược giám sát.

3.2 Kết quả Vòng 2 — Phân cụm và hồ sơ rủi ro

Mô hình K-Means với $k=4$ phân chia 236 ca thành bốn nhóm có sự phân biệt nghiệp vụ rõ ràng. Kết quả được xác nhận bởi hai thuật toán kiểm chứng độc lập. Cụ thể là hai ca trong cụm C0 (#071 và #227) bị cô lập hoàn toàn trong không gian PCA tại $PC1 \approx 13-15$,

cách xa phần còn lại của dữ liệu. Còn DBSCAN thì gán nhãn nhiều cho đúng hai điểm này. Cả hai ca đều thuộc ca chiều với *CashDiff_Ratio* lần lượt là $15,3\times$ và $22,3\times$ doanh thu ca đó, xác nhận hiện tượng tích lũy tiền từ nhiều ca sáng chưa nộp.

Ngoài ra, cụm C3 chiếm 46,6% tổng số ca (110/236) và có gần 65% thuộc ca sáng (Hình 17), phù hợp với phát hiện EDA về ca sáng đông khách hơn. Đây là nhóm cần giám sát thường xuyên nhất do tần suất cao dù từng ca không cực đoan. Cụm C2 (28 ca) có doanh thu và số hóa đơn cao nhất trong bốn nhóm nhưng *Cash_Diff* không đặc biệt lớn, gợi ý đây là các ca bận rộn vận hành chứ không phải ca tích lũy tiền.



Hình 22. Phân bố cụm theo thời gian và tỷ lệ cụm theo tháng

Đồng thời, phân bố các cụm theo thời gian (Hình 22) cho thấy tỷ lệ ổn định qua năm tháng, không có tháng nào lệch khỏi xu hướng chung, xác nhận lại kết luận từ Vòng 1 về tính phi mùa vụ của rủi ro.

3.3 Kết quả Vòng 3 — Phát hiện dị biệt hành vi khách hàng

Sau chuẩn hóa Fuzzy Grouping, 101 ghi chú được gom thành các hồ sơ khách hàng riêng biệt. Ba khách hàng quen có đủ lịch sử giao dịch để xây dựng hồ sơ tin cậy. Phương pháp IQR per-customer phát hiện các giao dịch dị biệt theo hai chiều.

- Về giá trị, một số đơn hàng của “Ngọc PT” vượt ngưỡng $Q3 + 1,5\times IQR$ đáng kể, tập hợp giao dịch thông thường của khách này tập trung ở mức 20.000đ–50.000đ trong khi các điểm dị biệt đạt trên 60.000–90.000đ (đôi khi có các điểm dị biệt dưới 20.000đ).
- Về phương thức thanh toán, “Ngọc PT” có lịch sử 90% chuyển khoản nhưng xuất

hiện một giao dịch tiền mặt trên dòng thời gian, đây là tín hiệu kiểm toán quan trọng vì người dùng thông thường không thói quen thanh toán mà không có lý do cụ thể hoặc đặc biệt.

Cũng cần lưu ý rằng dị biệt IQR là tín hiệu thống kê, không phải bằng chứng gian lận. Các kết quả này được chuyển sang Vòng 4 như dữ liệu ngữ cảnh bổ sung cho quá trình ra quyết định của Rule Engine, không được sử dụng độc lập..

3.4 Kết quả Vòng 4 — Phân loại rủi ro và báo cáo tự động

Rule Engine xử lý 236 ca và phân loại như sau: 205 ca (86,9%) ở trạng thái bình thường, có 20 ca (8,5%) ở mức Chú ý (R3 - dư kết), 11 ca (4,7%) nằm ở mức Trung bình (R2 - nghi thất thoát), và 0 ca ở mức Cao. Không có ca nào kích hoạt đồng thời R2 và dị biệt thanh toán từ Vòng 3 trong tập dữ liệu này, mức Cao chưa được kích hoạt nhưng cơ chế logic đã được thiết lập sẵn cho dữ liệu tương lai. Đáng chú ý là toàn bộ 2 ca cụm C0, vốn có *Cash_Diff* cực lớn, được Rule Engine phân loại vào R3 (Chú ý) thay vì R2 (Trung bình hoặc Cao). Điều này thể hiện đúng vai trò của tầng Đánh giá trong CRISP-DM: tín hiệu thống kê từ K-Means được kiểm chứng lại bằng tri thức nghiệp vụ (C0 = tích lũy bàn giao, không phải thất thoát), tránh phát sinh cảnh báo sai có chi phí xử lý cao.

Báo cáo tự động sinh ra cho mỗi ca vi phạm bao gồm: thời gian ca, quy tắc vi phạm, mức độ rủi ro, diễn giải nguyên nhân bằng tiếng Việt, và khuyến nghị hành động cụ thể (ví dụ: trích xuất camera, đối soát sao kê ngân hàng, bổ sung nhân sự). Toàn bộ nội dung được sinh tự động bằng cơ chế mẫu chuỗi mà không sử dụng mô hình ngôn ngữ lớn phức tạp.

3.5 Thảo luận

Về kiến trúc lại: Kết quả thực nghiệm xác nhận sự bổ sung cần thiết giữa hai tầng. K-Means đơn thuần sẽ đánh dấu cụm C0 là bất thường nhất, nhưng Rule Engine nhận ra đây là đặc điểm vận hành (R3) chứ không phải rủi ro ưu tiên. Ngược lại, Rule Engine thuần túy không phát hiện được sự phân cực cấu trúc giữa C3 và C1, hai nhóm có *Cash_Diff* tương đồng về giá trị tuyệt đối nhưng khác biệt căn bản về áp lực giao dịch và nguy cơ sai sót. Sự kết hợp tạo ra một hệ thống vừa có khả năng khám phá cấu trúc ẩn, vừa có khả năng diễn giải minh bạch.

Về ràng buộc triển khai: Kiến trúc “không dùng mô hình ngôn ngữ lớn” là lựa chọn chủ động được nhóm cho là phù hợp với bài toán nhỏ này, không phải hạn chế kỹ thuật. Trong điều kiện thiết bị cửa hàng nhỏ lẻ, không có kết nối ổn định, không có ngân sách vận hành API, tính tất định và khả năng hoạt động ngoại tuyến của hệ thống là yêu cầu thực tiễn không thể thỏa hiệp.

Về giới hạn: Tập 101 ghi chú của Vòng 3 chỉ đủ xây dựng hồ sơ cho ba khách hàng quen, chưa đủ để phân tích hành vi toàn diện. Mức Cao của Rule Engine chưa được kích hoạt trong tập dữ liệu hiện tại, do đó chưa thể đánh giá độ chính xác của tổ hợp tín hiệu R2 và dị biệt ở Vòng 3. Ngoài ra, ngưỡng IQR được áp dụng cố định (hệ số 1.5) mà chưa được tối ưu hóa theo đặc điểm của từng cửa hàng.

4. Kết luận và hướng phát triển

4.1 Kết luận

Nghiên cứu đã xây dựng thành công một hệ thống kiểm toán tự động cho dữ liệu vận hành POS theo kiến trúc lai, tuân thủ quy trình CRISP-DM, hoàn toàn không phụ thuộc vào mô hình ngôn ngữ lớn. Hệ thống này đã trả lời được cả ba câu hỏi nghiên cứu đặt ra: K-Means kết hợp DBSCAN và Agglomerative Ward phân cụm thành công 236 ca thành bốn nhóm hành vi có ý nghĩa nghiệp vụ, Fuzzy Grouping kết hợp IQR chuẩn hóa và khai thác hiệu quả 101 ghi chú văn bản phi cấu trúc tiếng Việt, và Rule Engine với ba quy tắc kế toán tất định sinh được báo cáo cảnh báo tiếng Việt mà không cần bất kỳ dịch vụ tính toán ngoài nào.

Đóng góp có giá trị thực tiễn nhất của nghiên cứu là cơ chế kết hợp hai tầng: tầng học máy không giám sát khám phá cấu trúc ẩn trong dữ liệu, còn tầng Rule Engine diễn giải và phân tầng kết quả đó theo tri thức nghiệp vụ, đặc biệt là nhận định rằng cụm C0 là đặc điểm vận hành (dư kết bàn giao) chứ không phải gian lận, tránh phát sinh cảnh báo sai tốn kém. Toàn bộ Pipeline xuất ra bảng *POS_Master.csv* gồm 36 đặc trưng chuẩn hóa, khép kín một chu kỳ CRISP-DM và tạo nền tảng cho các vòng phân tích tiếp theo trong tương lai.

4.2 Hạn chế

Nghiên cứu có một số hạn chế cần được thừa nhận rõ ràng. Về dữ liệu, bộ dữ liệu được thu thập từ một cửa hàng cà phê quy mô nhỏ trong khoảng thời gian 5 tháng, với 236 ca làm việc và 101 ghi chú có tên khách hàng. Quy mô này đủ để minh chứng tính khả thi của phương pháp nhưng chưa đủ để đánh giá khả năng tổng quát hóa sang các loại hình kinh doanh khác hay các chuỗi có quy mô lớn hơn.

Về nhân giám sát, toàn bộ nhãn rủi ro trong hệ thống đều được sinh tự động bởi Rule Engine dựa trên tri thức nghiệp vụ của nhóm tác giả trong quá trình xây dựng phần mềm POS cho khách hàng, không có nhãn độc lập từ kiểm toán viên hay quản lý cửa hàng để đối chiếu. Điều này đồng nghĩa với việc chưa có cơ sở để tính độ chính xác (*precision*) hay độ nhạy (*recall*) theo nghĩa học máy có giám sát truyền thống.

Về Rule Engine, ba quy tắc R1–R3 được thiết lập dựa trên kinh nghiệm vận hành của một cửa hàng cụ thể. Ngưỡng IQR cố định ở hệ số 1,5 và mức Cao của Rule Engine chưa được kích hoạt trong tập dữ liệu hiện tại, nên chưa thể đánh giá thực nghiệm tổ hợp tín hiệu phức tạp nhất của hệ thống.

4.3 Hướng phát triển

Thứ nhất, mở rộng và đa dạng hóa dữ liệu bằng cách thu thập thêm dữ liệu vận hành từ nhiều cửa hàng thuộc các loại hình khác nhau (bán lẻ, nhà hàng, siêu thị nhỏ) trong thời gian dài hơn, đồng thời bổ sung quy trình gán nhãn thủ công từ quản lý cửa hàng để xây dựng tập dữ liệu có nhãn phục vụ đánh giá định lượng chính xác hơn.

Thứ hai, tối ưu hóa các ngưỡng quyết định thông qua các kỹ thuật tối ưu hóa có dữ liệu phản hồi (feedback loop): ngưỡng IQR có thể được hiệu chỉnh tự động theo phân phối lịch sử của từng khách hàng, và các quy tắc Rule Engine có thể được bổ sung điều kiện dựa

trên đặc điểm vận hành riêng của từng cửa hàng triển khai.

Thứ ba, tích hợp ngược vào hệ thống POS gốc dưới dạng mô-đun cảnh báo thời gian thực, cho phép Rule Engine chạy tự động sau mỗi ca chốt sổ thay vì xử lý theo lô như hiện tại, qua đó rút ngắn thời gian phát hiện rủi ro từ cuối tháng xuống còn cuối ca.

❖ **Conflicts of Interest:** *The authors pledge that there are no conflicts of interest related to the research, data collection, and publication of this paper.*

❖ **Acknowledgments:** *The authors would like to express their sincere gratitude to Dr. Nguyen Tan Trung and Teaching Assistant Le Thinh for their dedicated guidance and valuable professional feedback throughout the course on Data Mining and Applications at Ho Chi Minh City University of Education.*

TÀI LIỆU THAM KHẢO

- Ardo Kusdaryanto, C. D. (2026). The Use of the K-Means Algorithm in Analyzing E-Commerce Consumer Segmentation: A Case Study of the Online Retail Dataset. *JURNAL TEKNOLOGI DAN OPEN SOURCE*, 8(2). doi:10.36378/jtos.v8i2.4798
- Edgar Alonso Lopez-Rojas. (2016). PAYSIM: A FINANCIAL MOBILE MONEY SIMULATOR FOR FRAUD DETECTION. *28th European Modeling and Simulation Symposium*, (pp. 1-7).
- Joe H. Ward, J. (1963). Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301), 236-244. doi:https://doi.org/10.2307/2282967
- Lopez-Rojas, E. A. (2016). *Applying Simulation to the Problem of Detecting Financial Fraud*. Blekinge: Department of Computer Science and Engineering Blekinge Institute of Technology.
- Martin Ester, H.-P. K. (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. doi:https://dl.acm.org/doi/10.5555/3001460.3001507
- Rüdiger Wirth, J. H. (2000). CRISP-DM: Towards a Standard Process Model for Data. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29-40). Manchester.
- Umair Shafique, H. Q. (2014). A Comparative Study of Data Mining Process Models (KDD, CRISP-DM and SEMMA). *International Journal of Innovation and Scientific Research*, 21-224.
- Wang Yundong, A. Z. (2023). *Credit Card Fraud Identification using Logistic Regression and Random Forest*. doi:10.31185/wjcms.184
- Yusuf Sahin, E. D. (2011). Detecting Credit Card Fraud by ANN and Logistic. *2011 International Symposium on Innovations in Intelligent Systems and Applications*, (pp. 1-4). doi:https://doi.org/10.1109/INISTA.2011.5946108

PHỤ LỤC

Đường dẫn web app: <https://data-mining-work-shift-audit-data-a.vercel.app/>

Tài liệu đính kèm trong tệp zip diễn giải ý nghĩa các cột của từng file .csv: *Data Dictionary Document.pdf*